

Análisis Comparativo de Eficiencia: Pseudoinversa de Moore-Penrose vs. Descenso de Gradiente

Programación Numérica - FINESI

1. Resumen del Estudio

El presente informe examina el desempeño de dos enfoques matemáticos esenciales para la resolución de problemas de regresión lineal: la solución analítica mediante la **Pseudoinversa de Moore-Penrose** y la aproximación iterativa a través del **Descenso de Gradiente**. El objetivo central de la regresión es minimizar la suma de los errores cuadráticos (OLS) para estimar los parámetros que mejor modelan la relación entre variables independientes y dependientes.

1.1. Fundamento Teórico

La **Pseudoinversa de Moore-Penrose** proporciona una solución exacta y determinista utilizando operaciones de álgebra lineal (específicamente la descomposición en valores singulares, SVD). Aunque garantiza el error mínimo global, su complejidad computacional se vuelve prohibitiva y su estabilidad decrece ante matrices mal condicionadas o de gran volumen.

Por el contrario, el **Descenso de Gradiente** opera como un algoritmo de optimización iterativo. Ajusta los coeficientes moviéndose en la dirección opuesta al gradiente de la función de coste. Su eficacia depende crucialmente de hiperparámetros como la *tasa de aprendizaje* (α). A pesar de no ofrecer una solución exacta inmediata, destaca por su escalabilidad y robustez en conjuntos de datos masivos.

1.2. Metodología de Referencia

En la literatura analizada, se realizaron pruebas con datos sintéticos y reales (datasets *California Housing* y *Diabetes*). Las métricas de evaluación incluyeron el Tiempo de Ejecución, el Error Cuadrático Medio (MSE) y la convergencia. Los resultados indicaron que, si bien la Pseudoinversa es superior en precisión y velocidad para muestras pequeñas (n bajo), el Descenso de Gradiente (y sus variantes estocásticas) es la opción viable para entornos de *Big Data* o alta dimensionalidad.

2. Análisis de Rendimiento: Implementación Práctica

Con el fin de validar los conceptos teóricos, se llevó a cabo una prueba empírica comparando la función nativa de regresión lineal de R (`lm`), basada en métodos matriciales directos, frente a una implementación del algoritmo de Descenso de Gradiente.

Se midieron el tiempo de cómputo y el uso de memoria RAM para conjuntos de datos incrementales desde 100 hasta 10,000 observaciones.

2.1. Resultados Tabulados

La Tabla 1 resume los datos obtenidos mediante la librería `bench`, garantizando igualdad de condiciones para ambos algoritmos.

Cuadro 1: Comparativa de consumo de recursos: `lm()` vs. Gradiente

Tamaño (n)	Método	Tiempo (s)	Memoria (Bytes)
100	<code>lm</code>	5.431	104,573,176
100	Gradiente	0.005	143,432
1,000	<code>lm</code>	2.769	967,960,000
1,000	Gradiente	0.030	800,048
5,000	<code>lm</code>	16.215	4,934,680,000
5,000	Gradiente	0.566	4,000,048
10,000	<code>lm</code>	10.175	9,862,360,000
10,000	Gradiente	0.352	8,000,048

2.2. Representación Gráfica

A continuación, se presentan los gráficos generados a partir de los datos experimentales, ilustrando la disparidad en la escalabilidad de ambos métodos.




Figura 1: Evolución del tiempo de cómputo según el tamaño de la muestra.




Figura 2: Consumo de memoria. Nótese la escala logarítmica debido a la gran diferencia de magnitudes.

3. Discusión y Conclusiones

El análisis de los resultados revela una diferencia sustancial en la eficiencia de ambos algoritmos.

- **Eficiencia Temporal:** El método del Gradiente Descendente mantiene tiempos de ejecución inferiores a 1 segundo incluso para 10,000 datos. Por el contrario, la función `lm` muestra un comportamiento irregular y costoso, llegando a superar los 16 segundos.
- **Consumo de Memoria:** La diferencia es aún más crítica en el uso de RAM. Mientras que el Gradiente muestra un crecimiento lineal controlado, el método

matricial (`lm`) escala drásticamente, consumiendo gigabytes de memoria para procesar dataset relativamente pequeños.

Esto se debe a la naturaleza de las operaciones: `lm` intenta resolver el sistema mediante operaciones matriciales completas (inversión o descomposiciones QR) que tienen una complejidad computacional elevada ($O(n^3)$ o $O(nd^2)$). En contraste, el Gradiente Descendente realiza actualizaciones vectoriales ligeras, demostrando ser la opción superior para tareas repetitivas o grandes volúmenes de datos donde la aproximación iterativa es suficiente y mucho más barata computacionalmente.